

Table of Contents

Wstęp	1
Rozdział 1. Kredyt i ocena zdolności kredytowej – ujęcie teoretyczne	2
1.1. Pojęcie kredytu i ryzyka kredytowego	3
1.2. Tradycyjne metody oceny zdolności kredytowej	5
1.2.1. Metody eksperckie i scoringowe	5
1.2.2. Regulacje prawne i standardy branżowe	6
1.3. Ograniczenia klasycznych metod scoringowych	7
1.4. Kierunki modernizacji oceny zdolności kredytowej	8
Rozdział 2. Uczenie maszynowe w zastosowaniach finansowych	9
2.1. Podstawy uczenia maszynowego	9
2.1.1. Taksonomia metod uczenia maszynowego	9
2.1.2. Kluczowe pojęcia: cechy, etykiety, nadmierne dopasowanie, walidacja	11
2.2. Zastosowanie uczenia maszynowego w sektorze finansowym	12
2.2.1. Przegląd zastosowań w zarządzaniu ryzykiem	12
2.2.2. Credit scoring oparty na metodach ML – przegląd literatury	13
2.3. Charakterystyka wybranych algorytmów	14
2.3.1. Sieci neuronowe z długą pamięcią krótkotrwałą (LSTM)	14
2.3.2. Lasy losowe (Random Forest)	16
2.3.3. Gradient Boosting – algorytm XGBoost.....	17
2.4. Porównanie algorytmów ML z klasycznymi metodami scoringowymi	18
2.5. Wyzwania etyczne i regulacyjne stosowania ML w ocenie kredytowej	19
Rozdział 3. Metodologia badań i projekt systemu	20
3.1. Cel i zakres badań	21
3.2. Postawione hipotezy badawcze.....	21
3.3. Struktura i charakterystyka danych dłużników	21
3.3.1. Źródła i sposób pozyskania danych	21
3.3.2. Opis zmiennych wejściowych i zmiennej docelowej	21
3.3.3. Preprocessing danych: czyszczenie, normalizacja, inżynieria cech	21
3.4. Projekt architektury systemu eksperymentalnego	21
3.4.1. Architektura ogólna i przepływ danych	21
3.4.2. Warstwa backendowa.....	21
3.4.3. Integracja modeli AI z systemem.....	21
3.4.4. Warstwa frontendowa.....	21

3.5. Obsługa wyjątków i scenariusze brzegowe	21
3.6. Narzędzia i środowisko technologiczne	21
Rozdział 4. Implementacja i trenowanie modeli	21
4.1. Podział zbioru danych i strategia walidacji	22
4.1.1. Podział na zbiór treningowy, walidacyjny i testowy	22
4.1.2. Techniki radzenia sobie z niezbalansowaniem klas (SMOTE, ważenie)	24
4.2. Implementacja modelu LSTM	26
4.2.1. Dobór architektury sieci i hiperparametrów	26
4.2.2. Proces trenowania i krzywe uczenia	28
4.3. Implementacja modelu Random Forest	30
4.3.1. Dobór liczby drzew i głębokości	30
4.3.2. Ważność cech	32
4.4. Implementacja modelu XGBoost	33
4.4.1. Strojenie hiperparametrów – Grid Search i Cross-Validation	34
4.4.2. Analiza wkładu cech (SHAP values)	36
4.5. Walidacja i testowanie modeli w środowisku eksperymentalnym	38
Rozdział 5. Analiza wyników i ocena modeli	39
5.1. Metryki oceny jakości modeli klasyfikacyjnych	40
5.1.1. Dokładność, precyzja, czułość, F1-Score	40
5.1.2. Krzywa ROC i pole pod krzywą (AUC-ROC)	40
5.1.3. Macierz pomyłek i analiza błędów klasyfikacji	40
5.2. Wyniki modeli – zestawienie porównawcze	40
5.2.1. Wyniki modelu LSTM	40
5.2.2. Wyniki modelu Random Forest	40
5.2.3. Wyniki modelu XGBoost	40
5.3. Wzajemne porównanie modeli LSTM, Random Forest i XGBoost	40
5.4. Porównanie z klasycznymi metodami scoringowymi i istniejącymi rozwiązaniami	40
5.5. Interpretowalność modeli i ich przydatność decyzyjna	40
5.6. Dyskusja wyników i weryfikacja hipotez badawczych	40
Zakończenie	40
Bibliografia	40
Spis tabel	43
Spis rysunków i wykresów	43

Wstęp

Działalność kredytowa należy do fundamentów współczesnej bankowości, a nieodłącznie wiąże się z nią ryzyko kredytowe, rozumiane jako możliwość poniesienia przez bank straty wskutek niewywiązania się dłużnika ze zobowiązań. Podstawowym narzędziem ograniczania tego ryzyka jest ocena zdolności kredytowej, której sformalizowaną i zobiektywizowaną postacią stał się scoring kredytowy. Przez dziesięciolecia opierał się on na modelach statystycznych, przede wszystkim regresji logistycznej i kartach scoringowych, opisujących klienta w pojedynczym przekroju, najczęściej na etapie wniosku kredytowego. Tymczasem zarówno praktyka zarządzania ryzykiem, jak i obowiązujące regulacje — w tym art. 70 ustawy Prawo bankowe oraz wytyczne europejskiego nadzoru dotyczące monitorowania kredytów [9] — coraz wyraźniej przesuwają akcent z jednorazowej decyzji ku ciągłej obserwacji ekspozycji oraz wczesnemu wykrywaniu pogarszającej się sytuacji dłużnika.

Klasyczne metody scoringowe, mimo niekwestionowanych zalet, napotykają w tym kontekście istotne ograniczenia. Zakładają z góry liniową postać modelowanych zależności, wymagają pracochłonnej i wymagającej wiedzy eksperckiej inżynierii cech, a przede wszystkim opisują klienta statycznie, z trudem uwzględniając dynamikę jego zachowania w czasie. Rozwój uczenia maszynowego, a w szczególności sieci neuronowych zdolnych do przetwarzania danych sekwencyjnych, otwiera możliwość modelowania ryzyka jako funkcji następstwa zdarzeń płatniczych, a nie pojedynczego pomiaru. Właśnie ta perspektywa — traktowanie oceny spłaty długu jako zagadnienia dynamicznego, rozwijającego się w czasie — wyznacza temat niniejszej pracy.

Celem pracy jest zbadanie możliwości wspomagania oceny zdolności kredytowej z wykorzystaniem metod uczenia maszynowego, ze szczególnym uwzględnieniem porównania ujęcia statycznego i dynamicznego. Przedmiotem badań uczyniono trzy klasyfikatory reprezentujące odmienne rodziny algorytmiczne: lasy losowe oraz wzmacnianie gradientowe (XGBoost), operujące na zagregowanym wektorze cech, a także sieć z długą pamięcią krótkotrwałą (LSTM), przetwarzającą sześciomiesięczną historię płatniczą jako szereg czasowy. Wszystkie modele zbudowano i oceniono na publicznym zbiorze UCI „default of credit card clients”, obejmującym 30 000 klientów kart kredytowych, a całość osadzono w eksperymentalnym systemie złożonym z warstwy frontendowej, backendowej oraz dedykowanego serwisu predykcyjnego. Termin „dynamiczne” w tytule

pracy odnosi się przy tym nie do cyklicznej aktualizacji modelu, lecz do architektury sekwencyjnej, która z założenia traktuje ocenę jako funkcję przebiegu zdarzeń, a nie pomiar statyczny. Konsekwentnie odróżniono również zdolność kredytową w rozumieniu art. 70 Prawa bankowego, ocenianą między innymi na podstawie dochodu, od behawioralnego ryzyka niespłacenia mierzonego na danych historii płatniczej, które stanowi właściwy przedmiot części empirycznej; brak danych dochodowych w wykorzystanym zbiorze potraktowano jako świadomie przyjęte ograniczenie pracy.

Tak sformułowany cel prowadzi do zasadniczego pytania badawczego: czy i w jakim stopniu metody uczenia maszynowego, a w szczególności ujęcie sekwencyjne, poprawiają jakość oceny ryzyka niespłacenia względem klasycznego podejścia scoringowego. Pytanie to rozwinięto w postaci szczegółowych hipotez badawczych w rozdziale 3, a ich weryfikację oparto na porównaniu modeli za pomocą metryk niezależnych od progu klasyfikacyjnego, przede wszystkim pola pod krzywą ROC, na zestawieniu z klasycznym modelem referencyjnym oraz na analizie interpretowalności predykcji. Punktem odniesienia dla przyjętego podejścia są szeroko zakrojone badania porównawcze metod klasyfikacji w scoringu [10], a także analizy prowadzone wprost na wykorzystanym tu zbiorze danych [13].

Praca składa się z pięciu rozdziałów. Rozdział 1 wprowadza w teorię kredytu i oceny zdolności kredytowej, omawiając tradycyjne metody scoringowe, ich ramy regulacyjne oraz ograniczenia. Rozdział 2 przedstawia podstawy uczenia maszynowego, jego zastosowania w sektorze finansowym oraz charakterystykę trzech badanych algorytmów wraz z wyzwaniem etycznymi i regulacyjnymi. Rozdział 3 formułuje cel i hipotezy badawcze, opisuje strukturę danych oraz projekt systemu eksperymentalnego. Rozdział 4 dokumentuje implementację i trenowanie modeli, w tym strategię walidacji, sposób radzenia sobie z niebalansowaniem klas oraz dobór hiperparametrów. Rozdział 5 zawiera analizę wyników, wzajemne porównanie modeli, zestawienie z metodami klasycznymi oraz dyskusję w świetle postawionych hipotez. Całość zamyka zakończenie, podsumowujące wnioski oraz wskazujące kierunki dalszych badań.

Rozdział 1. Kredyt i ocena zdolności kredytowej – ujęcie teoretyczne

1.1. Pojęcie kredytu i ryzyka kredytowego

Kredyt bankowy stanowi jedną z podstawowych czynności bankowych, a jego istotę określa ustawodawca w art. 69 ustawy Prawo bankowe [1]. Zgodnie z przyjętą tam konstrukcją przez umowę kredytu bank zobowiązuje się oddać do dyspozycji kredytobiorcy

na czas oznaczony w umowie określoną kwotę środków pieniężnych z przeznaczeniem na ustalony cel, kredytobiorca zaś zobowiązuje się do korzystania z niej na warunkach określonych w umowie, zwrotu kwoty wykorzystanego kredytu wraz z odsetkami w oznaczonych terminach spłaty oraz zapłaty prowizji od udzielonego kredytu. Z prawnego punktu widzenia kluczowe jest zatem to, że środki przekazywane są zwrotnie i odpłatnie, a samo udzielenie kredytu rodzi po stronie banku ekspozycję trwającą przez cały okres umowy. Właśnie ta rozciągłość w czasie sprawia, że ocena kredytobiorcy nie może być traktowana jako jednorazowa czynność zamykająca się w momencie podpisania umowy, lecz jako zagadnienie obejmujące cały cykl życia ekspozycji.

Nieodłącznym następstwem działalności kredytowej jest ryzyko kredytowe, rozumiane jako możliwość poniesienia przez bank straty wskutek niewywiązania się kredytobiorcy z zobowiązań wynikających z umowy. W praktyce zarządzania ryzykiem przyjmuje się dekompozycję oczekiwanej straty na trzy współzależne komponenty: prawdopodobieństwo niewykonania zobowiązania (ang. probability of default, PD), stratę z tytułu niewykonania zobowiązania wyrażającą część ekspozycji niemożliwą do odzyskania (ang. loss given default, LGD) oraz wielkość ekspozycji w momencie niewykonania zobowiązania (ang. exposure at default, EAD). Iloczyn tych wielkości wyznacza stratę oczekiwaną, stanowiącą punkt odniesienia dla wyceny ryzyka, tworzenia rezerw oraz wymogów kapitałowych. Spośród wymienionych komponentów to właśnie prawdopodobieństwo niewykonania zobowiązania pozostaje najściślej powiązane z oceną indywidualnego klienta i to jego szacowaniu poświęcona jest w największym stopniu niniejsza praca.


Miejsce oceny zdolności kredytowej w cyklu kredytowym wyznaczają kolejne fazy obsługi ekspozycji: od etapu wnioskowania i decyzji o udzieleniu kredytu, poprzez bieżące administrowanie ekspozycją, aż po jej windykację w przypadku pogorszenia sytuacji dłużnika. Na etapie wniosku ocena ma charakter prognostyczny i opiera się na danych deklarowanych oraz historii zewnętrznej, natomiast w fazie obsługi pojawia się możliwość wykorzystania danych behawioralnych, odzwierciedlających rzeczywisty sposób korzystania z kredytu. Zarządzanie ryzykiem kredytowym obejmuje przy tym nie tylko moment udzielenia finansowania, lecz również jego późniejsze monitorowanie [22, s. 94], co stanowi naturalny punkt wyjścia dla rozważań nad dynamicznym ujęciem oceny prowadzonych w dalszej części pracy.

Narzędziem, które umożliwiło sformalizowanie i zobiektywizowanie tej oceny, jest scoring kredytowy. W klasycznym ujęciu credit scoring definiowany jest jako „Credit scoring is the set of decision models and their underlying techniques” [2, s. 1], a więc zbiór modeli decyzyjnych i technik leżących u ich podstaw, służących wspomaganie decyzji o udzieleniu

kredytu. W literaturze przedmiotu scoring opisywany jest również jako kluczowa technika oceny ryzyka pozwalająca analizować i kwantyfikować ryzyko związane z klientem [22, s. 93]. Tak rozumiany scoring nie jest jedynie metodą obliczeniową, lecz całością procedury przekładającej dane o kliencie na ocenę liczbową wspierającą decyzję kredytową.

Konieczne jest przy tym precyzyjne odróżnienie scoringu od potocznie utożsamianej z nim zdolności kredytowej w znaczeniu zdolności do spłaty (ang. creditworthiness). W ujęciu teoretycznym creditworthiness rozumie się jako gotowość i zdolność do spłaty zobowiązania (ang. willingness and ability to repay) [3], a zatem jako ocenę formułowaną przez kredytodawcę, a nie obiektywnie mierzalną cechę osoby. Zwraca się uwagę, że zdolność do spłaty nie jest atrybutem klienta w takim sensie, w jakim są nimi wzrost czy dochód, lecz wynikiem osądu dokonywanego przez kredytodawcę na podstawie dostępnych przesłanek [2, s. 1]. Scoring jest więc techniką wspomagającą sformułowanie owego osądu, nie zaś jego synonimem. Rozróżnienie to ma znaczenie nie tylko terminologiczne: w niniejszej pracy konsekwentnie oddziela się zdolność kredytową w rozumieniu art. 70 Prawa bankowego [1], ocenianą między innymi na podstawie dochodu na etapie wniosku, od behawioralnego ryzyka niespłacenia, mierzonego na danych historii płatniczej i stanowiącego właściwy przedmiot części badawczej.

Cykl życia ekspozycji kredytowej i miejsce oceny



Windykacja uruchamiana warunkowo, w razie pogorszenia sytuacji dłużnika.

Rysunek 1.1. Cykl życia ekspozycji kredytowej i miejsce oceny. Źródło: opracowanie własne.

1.2. Tradycyjne metody oceny zdolności kredytowej

Historyczny rozwój metod oceny zdolności kredytowej można przedstawić jako stopniowe przechodzenie od osądu eksperckiego ku sformalizowanym modelom statystycznym, a w dalszej kolejności ku metodom uczenia maszynowego. Każdy z tych etapów odpowiadał na ograniczenia poprzedniego, zwiększając obiektywność, powtarzalność i skalowalność oceny. W niniejszym podrozdziale omówiono dwa filary

tradycyjnego podejścia: dorobek metodyczny wypracowany od oceny eksperckiej po scoring statystyczny oraz ramy regulacyjne, w których oceny te są dokonywane.



Rysunek 1.2. Ewolucja metod oceny zdolności kredytowej. Źródło: opracowanie własne.

1.2.1. Metody eksperckie i scoringowe

Najwcześniejsze podejście do oceny zdolności kredytowej opierało się na osądzie doświadczonego analityka, który na podstawie wiedzy o kliencie formułował decyzję kredytową. Usystematyzowaniem tej praktyki stała się zasada pięciu C (ang. five C's of credit), porządkująca przesłanki oceny wokół charakteru kredytobiorcy (character), jego zdolności do obsługi długu (capacity), posiadanego kapitału (capital), zabezpieczeń (collateral) oraz warunków otoczenia gospodarczego (conditions). Ocena ekspercka, choć elastyczna i wrażliwa na kontekst, obarczona była subiektywizmem, niską powtarzalnością i trudnością w skalowaniu, co przy rosnącej liczbie wniosków detalicznych okazało się barierą trudną do przezwyciężenia [3].

Odpowiedzią na te ograniczenia stał się scoring statystyczny, w którym decyzję wspiera model zbudowany na danych historycznych o klientach i ich rzeczywistym zachowaniu kredytowym. Przeglądy metod klasyfikacji stosowanych w scoringu konsumenckim wskazują, że dominującą rolę odgrywa w nim regresja logistyczna, ceniona za stabilność, interpretowalność oraz bezpośrednią możliwość przełożenia wyniku na prawdopodobieństwo niewykonania zobowiązania [5]. Model regresji logistycznej szacuje to prawdopodobieństwo jako funkcję ważonej kombinacji cech wnioskodawcy, a estymowane współczynniki pozwalają wprost wskazać kierunek i siłę wpływu poszczególnych zmiennych, co ma istotne znaczenie wobec wymogu uzasadniania decyzji kredytowych.

Praktycznym wcieleniem modelu statystycznego jest karta scoringowa (ang. scorecard), przekształcająca wynik modelu w czytelny zestaw punktów przypisanych poszczególnym przedziałom wartości cech. Podkreśla się jednak, że jakość karty nie wynika z samego przetworzenia danych przez procedury obliczeniowe, lecz z rzetelnej analizy i wiedzy dziedzinowej towarzyszącej jej budowie, co oddaje uwaga, iż „Good scorecards are not built by passing data solely through a series of programs” [4, s. 4]. Budowa karty scoringowej jest zatem procesem łączącym aparat statystyczny z rozumieniem realiów kredytowych.

Kluczowym elementem przygotowania danych do takiego modelu jest transformacja zmiennych metodą wagi dowodu (ang. weight of evidence, WOE), polegająca na zastąpieniu wartości lub przedziałów cechy logarytmem stosunku udziału obserwacji dobrych do złych w danym przedziale [4, s. 65]. Transformacja ta porządkuje zmienne względem ryzyka, linearyzuje ich związek ze zmienną objaśnianą i łagodzi wpływ wartości skrajnych. Z transformacją WOE nierozzerwalnie związana jest miara wartości informacyjnej (ang. information value, IV), agregująca siłę predykcyjną całej zmiennej i wykorzystywana do selekcji cech do modelu [4, s. 78]. To właśnie konieczność ręcznego przeprowadzenia tego rodzaju inżynierii cech stanie się jednym z punktów odniesienia przy omawianiu ograniczeń podejścia klasycznego oraz przewag metod uczenia maszynowego.

1.2.2. Regulacje prawne i standardy branżowe

Ocena zdolności kredytowej nie jest pozostawiona swobodnemu uznaniu banku, lecz osadzona w ramach prawnych i nadzorczych, które wyznaczają zarówno jej obowiązkowy charakter, jak i minimalne standardy metodyczne. Fundament stanowi art. 70 ustawy Prawo bankowe [1], który uzależnia udzielenie kredytu od posiadania przez kredytobiorcę zdolności kredytowej, rozumianej jako zdolność do spłaty zaciągniętego kredytu wraz z odsetkami w terminach określonych w umowie. Z punktu widzenia tematu niniejszej pracy szczególnie istotne jest to, że regulacja ta nie ogranicza obowiązków banku do momentu udzielenia finansowania, lecz przewiduje również bieżące monitorowanie sytuacji kredytobiorcy w okresie obowiązywania umowy. Wymóg ciągłej kontroli spłaty stanowi normatywne uzasadnienie dla poszukiwania narzędzi umożliwiających wczesne wykrywanie pogarszającej się zdolności do obsługi długu.

Standardy metodyczne uszczegóławiają rekomendacje Komisji Nadzoru Finansowego. Rekomendacja T [7] odnosi się do dobrych praktyk w zakresie zarządzania ryzykiem detalicznych ekspozycji kredytowych, porządkując zasady badania zdolności kredytowej klientów indywidualnych, w tym ocenę obciążenia dochodu spłatą zobowiązań. Rekomendacja S [8] dotyczy ekspozycji zabezpieczonych hipotecznie i formułuje wymogi wobec procesu oceny w odniesieniu do kredytów mieszkaniowych, kładąc nacisk na

ostrożną ocenę zdolności kredytowej w długim horyzoncie. Obie rekomendacje, choć różnią się przedmiotem, wspólnie utrwalają zasadę, że ocena zdolności kredytowej powinna być oparta na rzetelnych danych oraz udokumentowanej metodyce.

Ramy o zasięgu europejskim wyznaczają Wytyczne Europejskiego Urzędu Nadzoru Bankowego w sprawie udzielania i monitorowania kredytów [9], które ujmują cały cykl życia ekspozycji w jednolitym standardzie. Szczególne znaczenie dla niniejszej pracy ma ta ich część, która poświęcona jest monitorowaniu kredytów oraz stosowaniu wskaźników wczesnego ostrzegania, sygnalizujących wzrost ryzyka jeszcze przed wystąpieniem zaległości w spłacie [9]. Wytyczne te przesuwają akcent z jednorazowej oceny na etapie wniosku ku ciągłej obserwacji ekspozycji, czyniąc z wczesnego ostrzegania oczekiwany element procesu kredytowego. W tym sensie obowiązujące regulacje wyznaczają kierunek, w którym podążają omawiane w dalszej części pracy metody oparte na danych behawioralnych i analizie sekwencji płatniczych.

1.3. Ograniczenia klasycznych metod scoringowych

Mimo niekwestionowanych zalet, klasyczne metody scoringowe wykazują ograniczenia, które przy rosnącej złożoności danych i oczekiwań regulacyjnych stają się coraz bardziej dotkliwe. Pierwsze z nich wynika z założeń statystycznych leżących u podstaw dominującej regresji logistycznej. Model ten zakłada w istocie liniową zależność między transformowanymi cechami a logarytmem szansy niewykonania zobowiązania, przez co wierne odwzorowanie złożonych, nieliniowych współzależności między zmiennymi wymaga ich uprzedniego, ręcznego przekształcenia. Porównawcze badania algorytmów klasyfikacji w scoringu wskazują, że metody zdolne do automatycznego modelowania nieliniowości i interakcji potrafią systematycznie poprawiać trafność predykcji względem podejścia liniowego [10], [11].

Drugim ograniczeniem, szczególnie istotnym dla niniejszej pracy, jest statyczny charakter klasycznej oceny. Tradycyjna karta scoringowa opisuje klienta w postaci pojedynczego przekroju (ang. snapshot), utrwalającego jego sytuację w określonym momencie, najczęściej na etapie wniosku. Tak skonstruowana ocena z trudem uwzględnia dynamikę zachowania kredytobiorcy w czasie, a zmiana jego sytuacji ujawnia się w modelu dopiero przy ponownej, okresowej rekalkulacji. Tymczasem ryzyko niespłacenia narasta zwykle stopniowo i znajduje odzwierciedlenie w sekwencji zdarzeń płatniczych, której pojedynczy przekrój z natury nie obejmuje.

Trzecie ograniczenie dotyczy pracochłonnej i wymagającej wiedzy eksperckiej inżynierii cech. Skuteczność klasycznego modelu w znacznym stopniu zależy od jakości ręcznie przygotowanych zmiennych, w tym omówionej wcześniej transformacji metodą

wagi dowodu oraz selekcji cech w oparciu o wartość informacyjną. Proces ten jest czasochłonny, podatny na subiektywne decyzje analityka i trudny do pełnego zautomatyzowania, a jego rezultat ogranicza górny pułap możliwości modelu [5].

Wymienione ograniczenia — przywiązanie do założeń liniowych, statyczne ujęcie klienta oraz zależność od ręcznej inżynierii cech — wyznaczają granicę użyteczności podejścia klasycznego i jednocześnie określają kierunek poszukiwań metod alternatywnych. Przejście od statycznego przekroju ku analizie sekwencji płatniczych w czasie, a więc od ujęcia statycznego ku dynamicznemu, stanowi pojęciowe ogniwo łączące niniejszy rozdział z prezentowanymi dalej metodami uczenia maszynowego, w szczególności z architekturą przetwarzającą dane jako sekwencję czasową.

1.4. Kierunki modernizacji oceny zdolności kredytowej

Wskazane ograniczenia podejścia klasycznego wyznaczają główne kierunki modernizacji oceny zdolności kredytowej. Najszerszym z nich jest wprowadzenie metod uczenia maszynowego, które dzięki zdolności do automatycznego wychwytywania nieliniowych zależności i interakcji między cechami pozwalają poprawić trafność predykcji bez konieczności narzucania z góry postaci funkcyjnej modelu. Systematyczne porównania algorytmów klasyfikacji na potrzeby scoringu potwierdzają, że nowoczesne metody uczenia maszynowego osiągają wyniki przewyższające klasyczne modele liniowe, choć kosztem niższej bezpośredniej interpretowalności [10]. Zagadnieniu temu poświęcony jest w całości rozdział 2 niniejszej pracy.

Drugim kierunkiem jest przejście od scoringu aplikacyjnego (ang. application scoring) ku scoringowi behawioralnemu (ang. behavioural scoring). O ile scoring aplikacyjny ocenia wnioskodawcę w momencie ubiegania się o kredyt, na podstawie danych dostępnych w chwili decyzji, o tyle scoring behawioralny wykorzystuje dane o rzeczywistym zachowaniu klienta już posiadającego ekspozycję, obserwowanym w kolejnych okresach [6]. To właśnie behawioralne ujęcie otwiera drogę do dynamicznego modelowania ryzyka, w którym sekwencja zdarzeń płatniczych traktowana jest jako szereg czasowy. Modele wykorzystujące taką strukturę danych do prognozowania i testów warunków skrajnych dla portfeli kart kredytowych wykazują, że uwzględnienie wymiaru czasowego zwiększa zdolność wczesnego rozpoznawania pogarszającej się sytuacji dłużnika [12].

Trzeci kierunek wiąże się z poszerzaniem zbioru wykorzystywanych danych poza informacje tradycyjnie gromadzone w procesie kredytowym o tak zwane dane alternatywne, opisujące zachowania klienta w innych obszarach jego aktywności. Choć dane tego rodzaju nie są przedmiotem części badawczej niniejszej pracy, stanowią istotny

element szerszego nurtu modernizacji, zwiększającego ilość przesłanek dostępnych dla modelu oceny. Niezależnie od źródła danych, wspólnym mianownikiem omawianych kierunków pozostaje dążenie do tego, by ocena ryzyka była nie tyle jednorazowym werdyktem, ile procesem ciągłym, w którym banki oceniają klientów nie tylko w chwili wniosku [22, s. 94].

Zwieńczeniem tych kierunków jest koncepcja systemów wczesnego ostrzegania, w których model na bieżąco analizuje dane behawioralne i sygnalizuje wzrost ryzyka niespłacenia, zanim ujawni się ono w postaci zaległości. Tak rozumiane wczesne ostrzeganie spina ze sobą omówione wcześniej wątki: regulacyjny wymóg monitorowania spłaty, dostępność danych behawioralnych oraz zdolność metod uczenia maszynowego do modelowania zależności czasowych. Stanowi ono bezpośrednie nawiązanie do tematu niniejszej pracy, w którym dynamiczne monitorowanie zdolności spłaty długu rozumiane jest jako analiza sekwencji płatniczej za pomocą sieci przetwarzającej szereg czasowy. Szczegółowemu omówieniu metod uczenia maszynowego, które umożliwiają realizację tej koncepcji, poświęcony jest następny rozdział.

Rozdział 2. Uczenie maszynowe w zastosowaniach finansowych

2.1. Podstawy uczenia maszynowego

Uczenie maszynowe stanowi dział sztucznej inteligencji zajmujący się konstruowaniem modeli, które na podstawie danych samodzielnie wyznaczają reguły odwzorowujące zależności między obserwacjami a interesującą badacza wielkością. W odróżnieniu od klasycznego programowania, w którym reguły formułuje wprost człowiek, w uczeniu maszynowym to algorytm wydobywa wzorce z przykładów, a jakość owego odwzorowania oceniana jest przez pryzmat zdolności do trafnego działania na danych wcześniej niewidzianych. Niniejszy podrozdział porządkuje podstawowy aparat pojęciowy, do którego odwołują się dalsze części pracy, w tym opis konkretnych algorytmów oraz decyzje implementacyjne podjęte w rozdziale 4.

2.1.1. Taksonomia metod uczenia maszynowego


Metody uczenia maszynowego tradycyjnie dzieli się na trzy zasadnicze rodziny, różniące się charakterem dostępnych danych oraz sposobem definiowania celu uczenia [14], [15]. W uczeniu nadzorowanym (ang. supervised learning) model uczony jest na zbiorze obserwacji opatrzonych znaną wartością docelową, zwaną etykietą, a jego zadaniem jest odwzorowanie zależności między cechami wejściowymi a tą wartością w

sposób umożliwiający predykcję dla nowych przypadków. W uczeniu nienadzorowanym (ang. unsupervised learning) etykiety nie występują, a algorytm poszukuje ukrytej struktury danych, na przykład skupień obserwacji podobnych do siebie. Uczenie ze wzmocnieniem (ang. reinforcement learning) opisuje natomiast sytuację, w której agent uczy się sekwencji decyzji poprzez interakcję ze środowiskiem i otrzymywane sygnały nagrody, co znajduje zastosowanie w zagadnieniach o charakterze sterowania, odległych od problematyki niniejszej pracy.

W obrębie uczenia nadzorowanego wyróżnia się dwa podstawowe typy zadań w zależności od natury zmiennej docelowej. Gdy wartość docelowa jest ciągła, mówi się o regresji, której celem jest przewidywanie wielkości liczbowej. Gdy zaś zmienna docelowa przyjmuje wartości z określonego, skończonego zbioru kategorii, zadanie określa się mianem klasyfikacji, a model przypisuje obserwację do jednej z klas, najczęściej szacując przy tym prawdopodobieństwo przynależności.

Z tej perspektywy ocena ryzyka niespłacenia, stanowiąca przedmiot części badawczej, jest typowym zagadnieniem klasyfikacji binarnej: każdej obserwacji odpowiada jedna z dwóch klas, oznaczających wystąpienie lub brak zdarzenia niewykonania zobowiązania w przyjętym horyzoncie. Model nie zwraca przy tym jedynie etykiety, lecz oszacowanie prawdopodobieństwa przynależności do klasy zdarzenia, które pełni rolę analogiczną do klasycznego wyniku scoringowego omówionego w rozdziale 1. Takie ujęcie pozwala traktować trzy badane algorytmy jako alternatywne realizacje tego samego zadania klasyfikacyjnego, różniące się jednak sposobem modelowania zależności oraz zdolnością do uwzględnienia czasowego wymiaru danych, do czego praca powraca przy rozróżnieniu ujęcia statycznego i dynamicznego.

Taksonomia metod uczenia maszynowego



Rysunek 2.1. Taksonomia metod uczenia maszynowego. Źródło: opracowanie własne.

2.1.2. Kluczowe pojęcia: cechy, etykiety, nadmierne dopasowanie, walidacja

Punktem wyjścia każdego modelu nadzorowanego jest reprezentacja obserwacji w postaci wektora cech (ang. features), czyli mierzalnych właściwości opisujących pojedynczy przypadek, oraz przypisanej mu etykiety (ang. label) wyrażającej wartość docelową. W problemie rozważanym w niniejszej pracy cechami są wielkości opisujące historię płatniczą i profil klienta, etykietą zaś informacja o wystąpieniu zdarzenia niewykonania zobowiązania. Jakość modelu zależy nie tylko od wyboru algorytmu, lecz w równym stopniu od sposobu przygotowania cech, co znajduje odzwierciedlenie w decyzjach dotyczących skalowania zmiennych podjętych w części implementacyjnej.

Aby ocena modelu odzwierciedlała jego rzeczywistą przydatność, a nie jedynie dopasowanie do danych uczących, zbiór dzieli się na rozłączne części: treningową, na której model jest dopasowywany, walidacyjną, służącą doborowi hiperparametrów i kontroli przebiegu uczenia, oraz testową, wykorzystywaną wyłącznie do końcowej oceny [15]. Rozdzielenie to wynika z fundamentalnej zasady, zgodnie z którą skuteczność modelu należy mierzyć na danych, których w procesie trenowania nie oglądał; w przeciwnym razie raportowane metryki opisują zdolność do zapamiętywania, nie zaś do generalizacji. Konsekwentne stosowanie tej zasady stanowi podstawę strategii walidacji przyjętej w rozdziale 4.

Centralnym zagadnieniem teoretycznym uczenia nadzorowanego jest kompromis między obciążeniem a wariancją (ang. bias-variance tradeoff) [14]. Model zbyt prosty cechuje się wysokim obciążeniem i niedostatecznie odwzorowuje zależności w danych, popełniając błąd systematyczny zarówno na zbiorze uczącym, jak i testowym. Model nadmiernie złożony osiąga natomiast wysoką wariancję: dopasowuje się do przypadkowego szumu w danych uczących, tracąc zdolność uogólniania. To drugie zjawisko, określane mianem nadmiernego dopasowania (ang. overfitting), objawia się rozejściem się jakości modelu na danych treningowych i walidacyjnych i stanowi główne zagrożenie dla wiarygodności modeli o dużej pojemności, w tym sieci neuronowych.

Przeciwdziałaniu nadmiernemu dopasowaniu służą techniki regularyzacji, ograniczające efektywną złożoność modelu i wymuszające preferencję rozwiązań prostszych [15]. W przypadku sieci neuronowych typowym mechanizmem jest losowe wyłączenie części neuronów w trakcie uczenia (ang. dropout), które zapobiega nadmiernemu uzależnieniu predykcji od pojedynczych połączeń, a także wczesne zatrzymanie uczenia (ang. early stopping) w momencie, gdy jakość na zbiorze walidacyjnym przestaje się poprawiać. Mechanizmy te, omawiane w warstwie teoretycznej w niniejszym podrozdziale, znajdują bezpośrednie zastosowanie w konfiguracji modelu sekwencyjnego opisanej w rozdziale 4, gdzie ich dobór warunkuje stabilność procesu trenowania.

2.2. Zastosowanie uczenia maszynowego w sektorze finansowym

Sektor finansowy należy do obszarów, w których metody uczenia maszynowego znalazły szczególnie szerokie zastosowanie, czemu sprzyjają dostępność dużych zbiorów danych transakcyjnych oraz bezpośrednie przełożenie trafności predykcji na wynik ekonomiczny. W niniejszym podrozdziale przedstawiono ogólny kontekst zastosowań w zarządzaniu ryzykiem, a następnie skupiono uwagę na właściwym dla tematu pracy nurcie scoringu kredytowego opartego na metodach uczenia maszynowego.

2.2.1. Przegląd zastosowań w zarządzaniu ryzykiem

W obszarze zarządzania ryzykiem metody uczenia maszynowego wspierają szereg powiązanych ze sobą zadań. Jednym z najwcześniej i najszerzej eksplorowanych jest wykrywanie nadużyć, w którym modele identyfikują transakcje odbiegające od typowych wzorców zachowania, co przy ogromnej liczbie operacji wymaga automatyzacji nieosiągalnej dla oceny eksperckiej. W zarządzaniu ryzykiem rynkowym uczenie maszynowe wykorzystywane jest do prognozowania zmienności i modelowania zależności między instrumentami, natomiast w obszarze przeciwdziałania praniu pieniędzy (ang. anti-money laundering, AML) służy wykrywaniu podejrzanych sekwencji przepływów. We

wszystkich tych zastosowaniach wspólnym mianownikiem jest przekształcanie dużych, złożonych zbiorów danych w ocenę ryzyka wspierającą decyzję [22].

Ryzyko kredytowe zajmuje wśród tych zastosowań miejsce szczególne, to bowiem na danych kredytowych prowadzono jedne z najobszerniejszych badań porównawczych metod klasyfikacji. Scoring kredytowy traktuje się w tym ujęciu jako element szerszej analityki ryzyka, w której model statystyczny lub uczony maszynowo dostarcza ilościowej oceny prawdopodobieństwa niewykonania zobowiązania, wykorzystywanej zarówno na etapie decyzji kredytowej, jak i w późniejszym monitorowaniu ekspozycji. Systematyczne porównania algorytmów na danych scoringowych wskazują, że przejście od metod klasycznych ku bardziej złożonym modelom uczenia maszynowego przynosi mierzalną poprawę zdolności dyskryminacyjnej [10], co czyni ten obszar naturalnym polem zastosowania badanych w pracy algorytmów.

2.2.2. Credit scoring oparty na metodach ML – przegląd literatury

Dorobek badawczy w zakresie scoringu kredytowego opartego na metodach uczenia maszynowego można uporządkować wokół dwóch przenikających się nurtów: porównawczego, dążącego do ustalenia, które algorytmy najlepiej rozwiązują problem klasyfikacji na danych kredytowych, oraz sekwencyjnego, przesuwającego punkt ciężkości z pojedynczego przekroju klienta ku analizie jego zachowania w czasie. Rozróżnienie to ma dla niniejszej pracy znaczenie zasadnicze, ponieważ wyznacza linię podziału między ujęciem statycznym a dynamicznym, wokół której zbudowano część badawczą.

Nurt porównawczy ukształtowały szeroko zakrojone badania benchmarkowe. Wczesne zestawienie metod klasyfikacji wykazało, że choć żadna pojedyncza technika nie dominuje bezwzględnie, modele bardziej złożone potrafią systematycznie przewyższać podejście liniowe, przy czym różnice bywają umiarkowane, a interpretowalność pozostaje istotnym kryterium wyboru [11]. Aktualizacja tych badań na szerszym zbiorze danych i bogatszym zestawie algorytmów potwierdziła przewagę metod zespołowych, w szczególności opartych na drzewach decyzyjnych, wskazując je jako rozwiązania o najkorzystniejszym stosunku trafności do nakładu [10]. W tym samym nurcie mieści się analiza przeprowadzona na zbiorze klientów kart kredytowych, stanowiącym podstawę części badawczej niniejszej pracy, w której porównano kilka technik eksploracji danych pod kątem trafności szacowania prawdopodobieństwa niewykonania zobowiązania [13]. Wnioski płynące z tych prac uzasadniają wybór lasów losowych oraz wzmacniania gradientowego jako reprezentantów silnych metod zespołowych w prowadzonym eksperymencie.

Nurt sekwencyjny wyrasta z obserwacji, że klasyczne ujęcie scoringowe sprowadza klienta do pojedynczego wektora cech, pomijając informację zawartą w następstwie

zdarzeń płatniczych. Modele dynamiczne, wykorzystujące następstwo obserwacji w czasie do prognozowania i testów warunków skrajnych, wykazały, że uwzględnienie wymiaru czasowego poprawia zdolność przewidywania niewypłacalności w portfelu kart kredytowych [12]. Wraz z rozwojem uczenia głębokiego nurt ten zwrócił się ku rekurencyjnym sieciom neuronowym zdolnym do bezpośredniego przetwarzania sekwencji. Zastosowanie sieci z długą pamięcią krótkotrwałą, wzbogaconej o mechanizm uwagi, do oceny wniosków w pożyczkach społecznościowych pozwoliło uzyskać poprawę trafności względem metod operujących na danych zagregowanych [19]. Podejście traktujące historię rachunku jako surową sekwencję transakcji, przetwarzaną przez sieć rekurencyjną bez ręcznej inżynierii cech, wykazało konkurencyjność takiego ujęcia wobec klasycznych modeli scoringowych [20]. Badania nad sekwencyjnym uczeniem głębokim na tabelarycznych danych finansowych, ukierunkowane wprost na monitorowanie ryzyka kredytowego, potwierdziły zaś przydatność modeli sekwencyjnych w zadaniu wczesnego rozpoznawania pogarszającej się sytuacji dłużnika [21].

Synteza obu nurtów prowadzi do wniosku, który organizuje konstrukcję części badawczej. Metody zespołowe oparte na drzewach wyznaczają wymagający punkt odniesienia w ujęciu statycznym, w którym klient opisany jest pojedynczym przekrojem cech, podczas gdy sieci rekurencyjne otwierają ujęcie dynamiczne, modelujące sekwencję historii płatniczej. Zestawienie tych dwóch perspektyw na jednym zbiorze danych, podjęte w niniejszej pracy poprzez porównanie lasów losowych i wzmacniania gradientowego z siecią o długiej pamięci krótkotrwałej, pozwala ocenić, czy i w jakim stopniu uwzględnienie wymiaru czasowego przekłada się na zdolność wczesnego ostrzegania o ryzyku niespłacenia.

2.3. Charakterystyka wybranych algorytmów

2.3.1. Sieci neuronowe z długą pamięcią krótkotrwałą (LSTM)

Sieci neuronowe z długą pamięcią krótkotrwałą (ang. long short-term memory, LSTM) stanowią szczególny rodzaj sieci rekurencyjnych, zaprojektowany w celu modelowania zależności w danych sekwencyjnych. Klasyczna sieć rekurencyjna (ang. recurrent neural network, RNN) przetwarza sekwencję krok po kroku, przekazując między kolejnymi krokami stan ukryty, który pełni rolę pamięci dotychczasowego przebiegu. W zamyśle architektura ta powinna umożliwiać uwzględnianie kontekstu z odległej przeszłości, w praktyce jednak napotyka zasadnicze ograniczenie określane mianem problemu znikającego gradientu.


Problem ten ujawnia się w trakcie uczenia metodą wstecznej propagacji błędu przez kolejne kroki czasowe. Sygnał gradientu, przenoszony wstecz przez wiele etapów

sekwencji, ulega wielokrotnemu przemnożeniu, wskutek czego maleje wykładniczo i zanika, zanim dotrze do wczesnych kroków. W konsekwencji klasyczna sieć rekurencyjna z trudem wychwytyje zależności długozasięgowe, ponieważ wpływ odległych obserwacji na bieżącą predykcję praktycznie zanika w procesie aktualizacji wag.

Architektura LSTM rozwiązuje to ograniczenie poprzez wprowadzenie odrębnego stanu komórki (ang. cell state), przenoszonego przez sekwencję z udziałem mechanizmów bramkowych, które regulują przepływ informacji. Istotę tego rozwiązania oddaje opis, zgodnie z którym polega ono na „introducing self-loops to produce paths where the gradient can flow for long durations” [15], a więc na wprowadzeniu pętli umożliwiających przepływ gradientu przez długie odcinki czasu. Koncepcję tę zawdzięcza się pierwotnej pracy nad sieciami o długiej pamięci krótkotrwałej [16], do której odwołuje się późniejsza literatura przedmiotu.

Działanie komórki LSTM opiera się na trzech bramkach sterujących stanem komórki. Bramka zapomnienia (ang. forget gate) decyduje, jaka część dotychczasowego stanu zostaje zachowana, bramka wejścia (ang. input gate) określa, jaka część bieżącej informacji zostaje do stanu dopisana, a bramka wyjścia (ang. output gate) wyznacza, jaka część stanu zostaje udostępniona jako wynik w danym kroku. Dzięki temu sieć uczy się selektywnie utrzymywać informację istotną przez wiele kroków i pomijać informację nieistotną, co umożliwia modelowanie zależności rozciągniętych w czasie.

Z punktu widzenia tematu niniejszej pracy właśnie ta zdolność czyni architekturę LSTM naturalnym narzędziem analizy historii płatniczej klienta. Sekwencja kolejnych okresów rozliczeniowych, obejmująca informacje o wysokości zadłużenia, dokonanych płatnościach i powstałych zaległościach, stanowi szereg czasowy, w którym istotne sygnały ryzyka mogą narastać stopniowo i ujawniać się w następstwie zdarzeń, a nie w pojedynczym przekroju. Model sekwencyjny pozwala uchwycić ten wzorzec narastania, realizując dynamiczne ujęcie oceny ryzyka, które w pracy przeciwstawiono statycznemu ujęciu metod operujących na zagregowanym wektorze cech.



Rysunek 2.2. Schemat komórki LSTM. Źródło: [27].

2.3.2. Lasy losowe (Random Forest)

Lasy losowe (ang. random forests) należą do metod zespołowych, których idea polega na łączeniu predykcji wielu prostszych modeli bazowych w jedną, stabilniejszą ocenę. Modelem bazowym jest tu drzewo decyzyjne, czyli struktura dzieląca przestrzeń cech kolejnymi warunkami logicznymi aż do przypisania obserwacji do klasy. Pojedyncze drzewo, choć interpretowalne, cechuje się wysoką wariancją i silną wrażliwością na konkretny zbiór uczący, co czyni je modelem niestabilnym.

Las losowy ogranicza tę wariancję dzięki połączeniu dwóch źródeł losowości. Pierwszym jest agregacja zbiorów bootstrapowych (ang. bagging), w której każde drzewo uczone jest na innej, losowo wybranej z powtórzeniami próbce danych. Drugim jest losowe ograniczanie zbioru cech rozpatrywanych przy każdym podziale węzła, dzięki któremu poszczególne drzewa stają się wzajemnie mniej skorelowane. Istotę metody trafnie ujmuje opis, zgodnie z którym buduje się „a large collection of de-correlated trees, and then averages them” [14], a zatem dużą kolekcję wzajemnie nieskorelowanych drzew, których predykcje następnie się uśrednia. Uśrednienie wielu nieskorelowanych modeli redukuje wariancję zespołu, nie zwiększając przy tym istotnie jego obciążenia.



Praktyczną zaletą lasów losowych, wykorzystywaną w części badawczej, jest możliwość oszacowania ważności cech (ang. feature importance). Miara ta, wyznaczana na podstawie wkładu poszczególnych zmiennych w poprawę jakości podziałów w drzewach zespołu, pozwala uszeregować cechy według ich wpływu na predykcję. Choć nie dostarcza ona pełnej interpretacji modelu, daje czytelną wskazówkę co do tego, które zmienne historii płatniczej najsilniej wiążą się z ryzykiem niewykonania zobowiązania, co czyni las losowy modelem stosunkowo przejrzystym mimo zespołowej konstrukcji [17].

2.3.3. Gradient Boosting – algorytm XGBoost

Wzmacnianie gradientowe (ang. gradient boosting) jest, podobnie jak las losowy, metodą zespołową opartą na drzewach decyzyjnych, różni się jednak od niego zasadniczo sposobem budowania zespołu. O ile las losowy uczy drzewa niezależnie i uśrednia ich predykcje, o tyle wzmacnianie konstruuje model sekwencyjnie, dodając kolejne drzewa tak, aby każde z nich korygowało błędy popełniane przez dotychczasowy zespół [14]. W ujęciu addytywnym predykcja powstaje jako suma wkładów kolejnych drzew, a każde nowe drzewo dopasowywane jest do gradientu funkcji straty, wskazującego kierunek najszybszej poprawy.

Algorytm XGBoost (ang. eXtreme Gradient Boosting) stanowi skalowalną realizację tej idei, która zyskała szerokie uznanie ze względu na efektywność i jakość predykcji. Jego funkcja celu łączy człon mierzący dopasowanie do danych z członem regularyzacyjnym, jawnie karzącym nadmierną złożoność pojedynczych drzew, co ogranicza ryzyko nadmiernego dopasowania charakterystyczne dla metod sekwencyjnych. Rozwiązanie to wyróżnia ponadto szereg usprawnień obliczeniowych, w tym efektywną obsługę rzadkich danych oraz zrównoleglenie konstrukcji drzew, dzięki którym algorytm dobrze skaluje się do dużych zbiorów [18].

Z perspektywy niniejszej pracy lasy losowe oraz wzmacnianie gradientowe reprezentują dwa komplementarne oblicza metod zespołowych opartych na drzewach, oba operujące na statycznym wektorze cech opisującym klienta. Ich wysoka skuteczność na danych tabelarycznych czyni je wymagającym punktem odniesienia, względem którego oceniana jest zdolność modelu sekwencyjnego do uzyskania dodatkowej wartości z czasowego uporządkowania danych. Tym samym oba algorytmy wyznaczają statyczną granicę porównania, dopełniającą dynamiczne ujęcie reprezentowane przez sieć LSTM.



Rysunek 2.3. Porównanie konstrukcji zespołu: bagging i boosting (zestawienie). Źródło: [28], [29].

2.4. Porównanie algorytmów ML z klasycznymi metodami scoringowymi

Zestawienie metod uczenia maszynowego z klasycznymi metodami scoringowymi, omówionymi w rozdziale 1, ujawnia szereg kompromisów, których rozstrzygnięcie zależy od kontekstu zastosowania. Najczęściej przywoływaną osią porównania jest napięcie między

zdolnością dyskryminacyjną a interpretowalnością. Metody zespołowe oraz sieci neuronowe, dzięki zdolności do modelowania nieliniowych zależności i interakcji między cechami bez ich uprzedniego ręcznego przygotowania, osiągają zwykle wyższą trafność niż regresja logistyczna, co potwierdzają szeroko zakrojone badania porównawcze [10], [11]. Przewaga ta okupiona jest jednak utratą bezpośredniej przejrzystości modelu, ponieważ związek między cechą a wynikiem przestaje być wyrażony pojedynczym, łatwym do zinterpretowania współczynnikiem.

Drugą osią porównania jest koszt obliczeniowy oraz złożoność procesu budowy modelu. Klasyczna karta scoringowa, choć pracochłonna na etapie inżynierii cech, pozostaje modelem lekkim i łatwym do wdrożenia oraz audytu. Modele uczenia maszynowego wymagają natomiast większych nakładów na strojenie hiperparametrów, kontrolę nadmiernego dopasowania oraz utrzymanie, a w przypadku sieci sekwencyjnych również na przygotowanie danych w postaci uporządkowanych czasowo sekwencji. Nakłady te przekładają się jednak na zdolność uchwycenia wzorców niedostępnych dla modelu liniowego, w tym dynamiki zachowania klienta w czasie.

Trzecią, szczególnie istotną w sektorze bankowym osią są wymogi regulacyjne. Obowiązek uzasadniania decyzji kredytowych sprawia, że interpretowalność nie jest jedynie wygodą analityczną, lecz warunkiem dopuszczalności modelu w procesie decyzyjnym. Z tego powodu wyższa trafność modeli złożonych nie przesądza automatycznie o ich przewadze praktycznej, a wybór metody wymaga wyważenia korzyści predykcyjnych względem wymogów przejrzystości i rozliczalności. Napięcie to wyznacza bezpośredni kontekst dla zagadnień omawianych w kolejnym podrozdziale oraz uzasadnia włączenie do części badawczej metod wyjaśniania predykcji.

2.5. Wyzwania etyczne i regulacyjne stosowania ML w ocenie kredytowej

Wzrost zdolności predykcyjnej modeli uczenia maszynowego pociąga za sobą wyzwania etyczne i regulacyjne, których waga w ocenie kredytowej jest szczególnie duża ze względu na bezpośredni wpływ decyzji na sytuację życiową klienta. Centralnym pojęciem tej problematyki jest wyjaśnialność modelu, rozumiana jako możliwość zrozumienia przestanek konkretnej predykcji. W literaturze interpretowalność określa się jako „the degree to which a human can understand the cause” decyzji [24], a więc stopień, w jakim człowiek jest w stanie pojąć przyczynę rozstrzygnięcia. Modele zespołowe i sieci neuronowe, ze względu na swoją złożoność, bywają określane mianem modeli czarnoskrzynkowych, co czyni zapewnienie owej wyjaśnialności zadaniem nietrywialnym.

Odpowiedzią na ten problem są metody wyjaśniania predykcji niezależne od architektury modelu, wśród których szczególne miejsce zajmuje podejście oparte na

wartości Shapleya, zaczerpniętej z teorii gier kooperacyjnych. Wartość ta wyraża średni krańcowy wkład danej cechy w predykcję, uśredniony po wszystkich możliwych konfiguracjach pozostałych cech, dzięki czemu pozwala przypisać poszczególnym zmiennym ich udział w konkretnym rozstrzygnięciu [24]. Praktyczną realizacją tej idei jest metoda SHAP (ang. SHapley Additive exPlanations), stanowiąca ujednolicone podejście do interpretacji predykcji modeli, które łączy spójność teoretyczną z efektywnością obliczeniową [23]. Metoda ta wykorzystywana jest w części badawczej niniejszej pracy do analizy wkładu cech w predykcje modelu wzmacniania gradientowego.

Drugim obszarem wyzwań jest ryzyko dyskryminacji. Model uczony na danych historycznych może utrwaląć obecne w nich uprzedzenia, a samo wykluczenie zmiennych chronionych, takich jak płeć czy pochodzenie, nie gwarantuje neutralności, ponieważ informacja o nich bywa zawarta pośrednio w innych cechach. Zjawisko to, określane mianem dyskryminacji pośredniej, wymaga świadomej kontroli wpływu zmiennych chronionych oraz dążenia do tego, by ich istotność w modelu pozostawała niska. Zagadnienie to wykracza poza warstwę techniczną i nadaje wyjaśnialności modelu wymiar etyczny.

Wymienione wyzwania znajdują odzwierciedlenie w ramach prawnych. Rozporządzenie w sprawie sztucznej inteligencji (unijny AI Act) [25] kwalifikuje systemy wykorzystywane do oceny zdolności kredytowej do kategorii zastosowań wysokiego ryzyka, wiążąc z nimi podwyższone wymogi w zakresie jakości danych, nadzoru człowieka oraz przejrzystości. Niezależnie od tego ogólne rozporządzenie o ochronie danych (RODO) [26] reguluje dopuszczalność decyzji opartych wyłącznie na zautomatyzowanym przetwarzaniu, przyznając osobie, której dane dotyczą, prawo do uzyskania wyjaśnienia oraz do interwencji człowieka. Regulacje te sprawiają, że wyjaśnialność modelu przestaje być postulatem dobrych praktyk, a staje się wymogiem normatywnym, co bezpośrednio uzasadnia uwzględnienie metod interpretacji predykcji w projekcie badawczym niniejszej pracy.

Rozdział 3. Metodologia badań i projekt systemu

3.1. Cel i zakres badań

3.2. Postawione hipotezy badawcze

3.3. Struktura i charakterystyka danych dłużników

3.3.1. Źródła i sposób pozyskania danych

3.3.2. Opis zmiennych wejściowych i zmiennej docelowej

3.3.3. Preprocessing danych: czyszczenie, normalizacja, inżynieria cech

3.4. Projekt architektury systemu eksperymentalnego

3.4.1. Architektura ogólna i przepływ danych

3.4.2. Warstwa backendowa

3.4.3. Integracja modeli AI z systemem

3.4.4. Warstwa frontendowa

3.5. Obsługa wyjątków i scenariusze brzegowe

3.6. Narzędzia i środowisko technologiczne

Rozdział 4. Implementacja i trenowanie modeli

Tytuł niniejszej pracy akcentuje dynamiczne monitorowanie zdolności spłaty długu, a przyjęty w rozdziale 3 cel badawczy – wspomaganie oceny ryzyka kredytowego metodami uczenia maszynowego – znajduje w tym miejscu swoje bezpośrednie przełożenie na warstwę implementacyjną. W ramach pracy zaimplementowano trzy różne klasyfikatory reprezentujące odmienne rodziny algorytmiczne: Random Forest (zespół drzew z agregacją bagging), XGBoost (gradient boosting sekwencyjny) oraz LSTM (rekurencyjną sieć neuronową). Dwa pierwsze operują na statycznym, zagregowanym obrazie klienta i odpowiadają klasycznemu ujęciu scoringowemu. Trzeci traktuje dane wejściowe jako szereg czasowy sześciu kolejnych miesięcy historii płatniczej, a więc modeluje progresję zachowań, a nie tylko ich jednorazowy stan. W tym ujęciu widoczne staje się znaczenie terminu „dynamiczne” z tytułu pracy: odnosi się on nie do cyklicznej aktualizacji modelu,

lecz do architektury LSTM, która z założenia traktuje ocenę jako funkcję sekwencji zdarzeń, a nie pomiar statyczny.

Rozdział opisuje wszystkie decyzje projektowe związane z trenowaniem modeli: sposób podziału zbioru, strategię walidacji, techniki uwzględnienia niezbalansowania klas, dobór hiperparametrów, a także narzędzia analizy ważności cech (feature importance dla RF oraz wartości SHAP dla XGBoost). Całość kodu trenującego znajduje się w pliku *main.py*, do którego w dalszej części rozdziału odwołano się przy omawianiu konkretnych konstrukcji. Ocena jakości poszczególnych modeli, wraz z porównaniem metryk i interpretacją wyników biznesowych, zostanie przedstawiona w rozdziale 5.


4.1. Podział zbioru danych i strategia walidacji

Rzetelna ocena modelu wymaga, by jego skuteczność była mierzona na danych, których w procesie trenowania nie oglądał. W przeciwnym razie raportowane metryki opisują jedynie zdolność do zapamiętywania, nie zaś do generalizacji. Przyjęta w pracy strategia opiera się na dwóch sprawdzonych rozwiązaniach: stratyfikowanym podziale na zbiór treningowy i testowy oraz, wyłącznie na potrzeby trenowania LSTM, dodatkowym wydzieleniu zbioru walidacyjnego z części treningowej.

4.1.1. Podział na zbiór treningowy, walidacyjny i testowy

Pełny zbiór UCI „default of credit card clients” liczy 30 000 rekordów. W pierwszym kroku wydzielono z niego zbiór testowy o udziale 30%, co odpowiada 9 000 obserwacji. Pozostałe 70% (21 000 rekordów) stanowi zbiór treningowy wspólny dla wszystkich trzech modeli. W przypadku LSTM z tego zbioru treningowego odcięto dodatkowo 20% jako zbiór walidacyjny, wykorzystywany przez mechanizm wczesnego zatrzymywania trenowania (*EarlyStopping*) oraz dynamiczną redukcję współczynnika uczenia (*ReduceLROnPlateau*). W efekcie otrzymano proporcje zilustrowane na rysunku 4.1: 56% trenowanie, 14% walidacja, 30% test.

Podział danych: train / val / test — stratyfikowany, seed = 42



Rysunek 4.1. Podział danych: train / walidacja / test. Źródło: opracowanie własne.

Podział wykonywany jest z użyciem funkcji *train_test_split* z pakietu *scikit-learn*, z ustawionym parametrem *stratify=y*. Zachowuje to w każdym podzbiorze pierwotną proporcję klas, około 78% klientów spłacających i 22% niespłacających. Stratyfikacja ma tu istotne znaczenie praktyczne: przy losowym podziale bez stratyfikacji w teście mogłaby znaleźć się próbka z niższym udziałem klasy mniejszościowej, co sztucznie zawyżałoby dokładność i zniekształcało recall. Parametr *random_state=42* gwarantuje powtarzalność eksperymentu.

```
X_train, X_test, y_train, y_test = train_test_split(
    X_scaled, y, test_size=0.3, stratify=y, random_state=42
)
```

Zbiór testowy pełni w eksperymencie rolę „zamrożoną”. Nie jest widziany przez modele na żadnym etapie trenowania ani doboru hiperparametrów. Dopiero w rozdziale 5, podczas finalnego raportu metryk, wchodzi on do analizy. Takie odseparowanie jest istotne, ponieważ nawet pozornie niewinne decyzje projektowe – na przykład wybór progu klasyfikacyjnego na podstawie wyników testowych – w praktyce prowadzą do wycieku informacji ze zbioru testowego do procesu trenowania, a tym samym do zawyżonej oceny modelu.

Zbiór walidacyjny LSTM wykorzystywany jest wyłącznie wewnętrznie, podczas trenowania sieci. Parametr *validation_split=0.2* przekazany do metody *fit* realizuje ten podział automatycznie, odcinając ostatnie 20% wierszy zbioru treningowego. Informacje

stąd płynące – wartość straty walidacyjnej oraz metryka AUC na walidacji – służą wyłącznie do sterowania procesem uczenia: zatrzymania go we właściwym momencie i obniżenia tempa uczenia, jeśli model utyka na plateau. Rysunek 4.1 przedstawia ten sam podział w dwóch ujęciach jako wykres pierścieniowy oraz poziomy pasek proporcji, co pozwala jednocześnie odczytać udziały procentowe i bezwzględne liczebności podzbiorów.


4.1.2. Techniki radzenia sobie z niezbalansowaniem klas (SMOTE, ważenie)

Zmienna docelowa *Default* w zbiorze UCI ma rozkład około 78/22 na korzyść klasy spłatającej. Niezbalansowanie to jest umiarkowane, w literaturze credit scoring bywają bowiem portfele, gdzie klasa mniejszościowa stanowi 2–3% rekordów. Niemniej nawet proporcja 22% wystarcza, by naiwne trenowanie na surowych danych prowadziło do modeli chętnie zwracających klasę większościową i bagatelizujących klasę klientów niesplatających. Z perspektywy celu pracy jest to sytuacja szczególnie niepożądana, ponieważ fałszywie negatywna diagnoza (przeoczenie ryzyka) kosztuje bank utratę kapitału, podczas gdy fałszywie pozytywna – jedynie utratę marży na niezawartej umowie. Priorytetem jest więc wysoki recall dla klasy mniejszościowej, nawet kosztem nieznacznego obniżenia precision.

W literaturze dwie rodziny metod dominują w podejściu do niezbalansowanych danych. Pierwsza modyfikuje rozkład zbioru treningowego poprzez oversampling klasy mniejszościowej lub undersampling klasy większościowej. Najbardziej rozpoznawalnym przedstawicielem tego nurtu jest metoda SMOTE (Synthetic Minority Over-sampling Technique), która generuje syntetyczne obserwacje klasy mniejszościowej przez interpolację liniową między najbliższymi sąsiadami w przestrzeni cech. Druga rodzina pozostawia dane nietknięte, a koryguje jedynie funkcję celu optymalizowaną przez klasyfikator, przypisując większą wagę pomyłkom na klasie mniejszościowej.

Rysunek 4.2 prezentuje efekt techniki SMOTE zastosowanej eksperymentalnie, na etapie analizy alternatyw, na pełnym zbiorze treningowym (21 000 obserwacji wykorzystywanym przez Random Forest i XGBoost); w finalnym pipeline'ie zrezygnowano z tej metody na rzecz ważenia klas opisanego poniżej. Wykres przedstawia efekt SMOTE w dwóch ujęciach. Pierwszy wiersz pokazuje liczebność klas przed i po, po zastosowaniu SMOTE każda klasa liczy około 16 tysięcy obserwacji. Drugi wiersz zawiera rzut PCA na przestrzeń dwuwymiarową, co pozwala ocenić, czy syntetyczne próbki rozkładają się sensownie względem oryginalnych. Można zauważyć, że nowe punkty klasy mniejszościowej zagęszczają obszary zajmowane już wcześniej przez prawdziwe przykłady i nie tworzą struktur oderwanych od danych oryginalnych. Samo w sobie nie jest to jednak gwarancja bezpieczeństwa, interpolacja liniowa w wielowymiarowej przestrzeni finansowej

bywa ryzykowna, bo może łączyć przypadki powierzchownie podobne, lecz merytorycznie różne (np. klienci o zbliżonym limicie, lecz zupełnie innym wzorcu zadłużenia).



Rysunek 4.2. Wpływ techniki SMOTE na balans klas. Źródło: opracowanie własne.

Z tego powodu w finalnej implementacji zdecydowano się na drugie podejście. Dla Random Forest oraz LSTM wykorzystano mechanizm `class_weight="balanced"`, który w trakcie trenowania waży obserwacje odwrotnie proporcjonalnie do częstości klasy. W przypadku LSTM wagi obliczane są jawnie funkcją `compute_class_weight` i przekazywane do metody `fit` jako słownik:

```
lstm_class_weights = compute_class_weight(  
    class_weight="balanced",  
    classes=np.array([0, 1]),  
    y=y_train_seq.values  
)  
lstm_class_weight_dict = {0: lstm_class_weights[0], 1: lstm_class_weights[1]}
```

Dla XGBoost równoważnym mechanizmem jest parametr *scale_pos_weight*, wyliczany jako stosunek liczebności klasy większościowej do mniejszościowej:

```
xgb = XGBClassifier(  
    ...  
    scale_pos_weight=(len(y) - sum(y)) / sum(y),  
    ...  
)
```

Powodów, dla których zrezygnowano z SMOTE na rzecz ważenia klas, jest kilka. Po pierwsze, ważenie nie zmienia rozkładu danych, oryginalne obserwacje pozostają nietknięte, a model uczy się ich naturalnej struktury, jedynie przywiązując większą wagę do błędów na klasie mniejszościowej. Po drugie, SMOTE wprowadza syntetyczne dane, które, choć lokalnie zgodne z rozkładem oryginału, nie odzwierciedlają rzeczywistej populacji klientów; w kontekście bankowym takie przekłamanie jest trudne do uzasadnienia przed regulatorem. Po trzecie, *class_weight* i *scale_pos_weight* są rozwiązaniami zintegrowanymi z biblioteką, co eliminuje dodatkowy etap preprocessingu i zmniejsza powierzchnię błędu w pipeline'ie.

4.2. Implementacja modelu LSTM

Model LSTM (Long Short-Term Memory) jest w pracy głównym nośnikiem dynamicznego ujęcia sformułowanego w tytule. W odróżnieniu od klasyfikatorów z sekcji 4.3 i 4.4, które operują na wektorze cech agregujących historię klienta do pojedynczej liczby lub zestawu liczb, LSTM otrzymuje na wejściu uporządkowaną sekwencję sześciu miesięcy historii płatniczej i uczy się rozpoznawać wzorce rozwijające się w czasie. Z perspektywy oceny zdolności spłaty oznacza to, że model nie zadowala się odpowiedzią na pytanie „jaki jest klient dzisiaj?”, lecz próbuje uchwycić trajektorię prowadzącą do tego stanu.

4.2.1. Dobór architektury sieci i hiperparametrów


Architekturę sieci dobrano z zamiarem utrzymania równowagi między zdolnością uogólniania a ryzykiem nadmiernego dopasowania (*overfitting*). Wejście sieci ma wymiar (6, 3): sześć kroków czasowych reprezentujących kolejne miesiące oraz trzy cechy na każdy krok, status płatności (*PAY*), saldo rachunku (*BILL_AMT*) i kwota wpłaty (*PAY_AMT*). Po warstwie wejściowej znajduje się pojedyncza warstwa LSTM o 32 jednostkach ukrytych, warstwa Dropout z prawdopodobieństwem 0,3, w pełni połączona warstwa Dense(16) z funkcją aktywacji ReLU oraz pojedynczy neuron wyjściowy z funkcją sigmoid, zwracający szacowane prawdopodobieństwo niewypłacalności. Całą konstrukcję opisuje następujący fragment kodu:

```

model = Sequential([
    Input(shape=(6, 3)),
    LSTM(32),
    Dropout(0.3),
    Dense(16, activation="relu"),
    Dense(1, activation="sigmoid")
])

```

Liczba 32 jednostek LSTM wynika z analizy przedstawionej na rysunku 4.4, na którym w jednym z paneli porównano AUC walidacyjne dla warstw o 16, 32, 64 i 128 jednostkach. Mniejsza liczba jednostek (16) skutkuje niedouczeniem – sieć nie jest w stanie zakodować subtelnych zależności w sekwencji. Większe warstwy (64, 128) osiągają AUC walidacyjne praktycznie identyczne z wariantem 32-jednostkowym, lecz kosztem wyraźnie wyższej liczby parametrów, dłuższego trenowania oraz większego ryzyka przeuczenia na dłuższych przebiegach. Wybór 32 jednostek uzasadniony jest zasadą oszczędności modelu. Przy tej samej skuteczności predykcyjnej preferowana jest architektura prostsza, lepiej regularyzowana przez Dropout i tańsza w eksploatacji.



Rysunek 4.3. Krzywe uczenia modelu LSTM. Źródło: opracowanie własne.

Dropout z prawdopodobieństwem 0,3 pełni rolę regularyzatora, wymuszając rozproszenie informacji w obrębie warstwy i ograniczając zależność predykcji od pojedynczych neuronów (szczegóły teoretyczne w sekcji 2.3.1). Wartości poniżej 0,2 dawały zbyt słabą regularyzację – sieć wykazywała wówczas oznaki przeuczenia; wartości powyżej 0,4 prowadziły natomiast do niedouczenia. Model tracił wówczas zdolność stabilnego uczenia wzorców. Warstwa Dense(16) pełni rolę klasyfikatora pracującego na wektorze cech ukrytych, zwróconym przez LSTM, a sigmoidalna warstwa wyjściowa mapuje wynik na przedział [0, 1] interpretowalny jako prawdopodobieństwo klasy dodatniej.

Dane zorganizowano w wymiar czasowy w następujący sposób. W oryginalnym zbiorze UCI kolumny *PAY_0*, *PAY_2*, *PAY_3*, *PAY_4*, *PAY_5*, *PAY_6* (przyjęta w źródle numeracja pomija *PAY_1*) reprezentują status płatności odpowiednio za wrzesień, sierpień, lipiec, czerwiec, maj i kwiecień. W implementacji kolejność kolumn została odwrócona, w tablicy wejściowej pierwszy krok czasowy odpowiada kwietniowi, a ostatni wrześniowi:

```
pay_seq_cols = ["PAY_6", "PAY_5", "PAY_4", "PAY_3", "PAY_2", "PAY_0"]
bill_seq_cols = ["BILL_AMT6", "BILL_AMT5", "BILL_AMT4", "BILL_AMT3", "BILL_AMT2", "BILL_AMT1"]
pay_amt_seq_cols = ["PAY_AMT6", "PAY_AMT5", "PAY_AMT4", "PAY_AMT3", "PAY_AMT2", "PAY_AMT1"]
```

Taki porządek ma istotne znaczenie merytoryczne. LSTM, przetwarzając sekwencję w porządku chronologicznym (od najstarszego do najnowszego miesiąca), aktualizuje swoje stany ukryte w kierunku przepływu czasu i uczy się progresji zachowań klienta, a nie ich statycznego obrazu. Najnowsze obserwacje, z wrześniowego salda i statusu płatności, trafiają do sieci na końcu sekwencji i mają największy wpływ na ostatni stan ukryty, z którego warstwa Dense generuje predykcję. Gdyby kolejność była odwrotna, sieć uczyłaby się tych samych zależności statystycznie, ale w kierunku wstecznym, co utrudnia interpretację modelu i kłóci się z intuicją biznesową: w praktyce bankowej analityk także rozpatruje historię od najstarszego wpisu do najnowszego.

Każda z trzech cech (*PAY*, *BILL_AMT*, *PAY_AMT*) została skalowana osobno, z użyciem niezależnego obiektu *StandardScaler*. Uzasadnieniem takiego wyboru jest wyraźnie różna skala wartości poszczególnych cech: *PAY* przyjmuje małe wartości całkowite, najczęściej w przedziale -2 do 8, *BILL_AMT* sięga setek tysięcy, a *PAY_AMT* również operuje w wysokich przedziałach, ale z zupełnie innym rozkładem niż *BILL_AMT*. Wspólne skalowanie zniekształciłoby zależności wewnątrz każdej cechy. Obiekty skalujące są zachowywane i wykorzystywane również w serwisie predykcyjnym (pliku *lstm_scalers.pkl*), co zapewnia spójność transformacji pomiędzy etapem trenowania a etapem wnioskowania.

4.2.2. Proces trenowania i krzywe uczenia


Sieć trenowana jest algorytmem Adam z domyślnymi ustawieniami oraz funkcją straty *binary_crossentropy*. Monitorowane są dwie metryki: ogólne AUC oraz – przekazywane jawnie poprzez callback – AUC walidacyjne, które steruje mechanizmem *EarlyStopping*. Trenowanie odbywa się przy batch size równym 256 oraz maksymalnej liczbie epok ustalonej na 60. W praktyce pełne 60 epok jest rzadko osiąganego, ponieważ *EarlyStopping* zatrzymuje proces, gdy przez pięć kolejnych epok metryka walidacyjna

przestaje się poprawiać, a następnie przywraca wagi modelu z momentu najlepszego wyniku.

```
lstm_callbacks = [  
    EarlyStopping(monitor="val_auc", mode="max", patience=5, restore_best_weights=True),  
    ReduceLROnPlateau(monitor="val_auc", mode="max", factor=0.5, patience=3, min_lr=1e-5),  
]
```

Drugi z callbacków *ReduceLROnPlateau* działa jako subtelniejsza forma adaptacji. Jeśli przez trzy epoki z rzędu AUC walidacyjne nie rośnie, współczynnik uczenia jest zmniejszany o połowę, aż do minimum 10^{-5} . Pozwala to sieci wyjść z płytkich minimów lokalnych, które czasem pojawiają się w okolicach plateau, bez konieczności sztywnego ustawiania harmonogramu uczenia (learning rate schedule) z góry.

Na rysunku 4.3 przedstawiono krzywe uczenia z typowego przebiegu treningu. Panel lewy pokazuje dokładność (accuracy), a panel prawy wartość funkcji straty; w obu przypadkach dla zbioru treningowego i walidacyjnego. Można zauważyć, że accuracy rośnie szybko w pierwszych epokach, a następnie stabilizuje się na poziomie zbliżonym do wartości testowej. Istotniejsza jest strata walidacyjna. Jej monotonicznie malejący przebieg przez większość epok świadczy o braku przeuczenia. Charakterystyczny symptom *overfittingu*, rosnąca strata walidacyjna przy nadal malejącej stracie treningowej, nie występuje, co jest zasługą dwóch mechanizmów działających łącznie: warstwy Dropout i wczesnego zatrzymywania.



Rysunek 4.4. Wpływ hiperparametrów LSTM na AUC walidacji. Źródło: opracowanie własne.

Rysunek 4.4 uzupełnia ten obraz, pokazując, jak na AUC walidacyjne wpływają trzy hiperparametry: liczba epok, rozmiar wsadu (batch size) oraz liczba jednostek LSTM. Każdy panel zawiera czerwone oznaczenie optimum. Analizując przebiegi, można zauważyć charakterystyczne „kolanko”: po ~15 epokach AUC osiąga plateau, a kolejne iteracje jedynie nieznacznie modyfikują wartości metryki; rozmiar wsadu poniżej 128 wprowadza nadmierny szum w gradiencie i spowalnia konwergencję, a powyżej 512, choć szybszy obliczeniowo, daje nieco słabszą stabilność numeryczną; liczba jednostek 32 okazuje się optymalna w sensie AUC, co potwierdza wybór dokonany na etapie projektowania.

LSTM w zaprojektowanej architekturze charakteryzuje się niskim kosztem obliczeniowym. Pełny trening na procesorze trwa kilka minut, co pozwala swobodnie eksperymentować z hiperparametrami bez konieczności wykorzystania GPU. Jest to konsekwencja krótkiego horyzontu czasowego (zaledwie 6 kroków) i niewielkiej liczby cech, sytuacja typowa dla scoringu kredytowego, odmienna od problemów NLP, gdzie sekwencje liczą setki lub tysiące tokenów.


4.3. Implementacja modelu Random Forest

Random Forest jest w pracy reprezentantem rodziny ensemble bagging, zespołu drzew decyzyjnych trenowanych niezależnie na bootstrapowych próbkach danych, których predykcje są agregowane przez głosowanie większościowe. Z punktu widzenia praktyki bankowej zaletą tego podejścia jest relatywnie dobra interpretowalność poprzez ważność cech (feature importance), szybkość trenowania oraz stabilność wyników. Pojedyncze drzewo jest słabym klasyfikatorem, lecz zespół redukuje wariancję i minimalizuje wpływ przypadkowych podziałów.

4.3.1. Dobór liczby drzew i głębokości

Konfiguracja klasyfikatora została ustalona na podstawie siatki wartości przetestowanych wzdłuż dwóch najistotniejszych hiperparametrów: liczby drzew (*n_estimators*) i maksymalnej głębokości (*max_depth*). Wyniki tego eksperymentu prezentuje rysunek 4.5, na którym w postaci heatmapy zestawiono AUC testowe dla poszczególnych kombinacji. Czerwone obramowanie oznacza konfigurację ostatecznie przyjętą:

```
rf = RandomForestClassifier(  
    n_estimators=500,  
    max_depth=10,  
    min_samples_leaf=5,  
    class_weight="balanced",  
    random_state=42
```

Rysunek 4.5. Random Forest — wpływ $n_estimators$ i max_depth na AUC. Źródło: opracowanie własne.

Liczbę drzew ustalono na 500, ponieważ dalsze jej zwiększanie powodowało jedynie marginalny przyrost AUC przy kwadratowym wzroście kosztu obliczeniowego: różnica między 500 a 1000 drzewami była na poziomie trzeciego miejsca po przecinku, niewspółmierna do dwukrotnego wydłużenia czasu trenowania. Jednocześnie 500 jest wartością na tyle dużą, by agregacja predykcji skutecznie redukowałą wariancję, co potwierdza widoczna w górnej części heatmapy asymptotyczność krzywej AUC względem liczby drzew.

Wybór $max_depth=10$ był mniej oczywisty. Drzewa płytsze (3–6) okazywały się niedouczone – zbyt słabo rozpoznawały nieliniowe zależności w cechach takich jak *utilization_rate* czy *BILL_trend*. Drzewa głębokie lub nieograniczone ($max_depth=None$) osiągały bardzo wysokie AUC treningowe, lecz na zbiorze testowym ich wyniki zaczynały spadać – symptom *overfittingu*. Głębokość 10 zachowuje balans między tymi skrajnościami: pozwala na uchwycenie interakcji drugiego i trzeciego rzędu między cechami, lecz nie dopuszcza do zapamiętywania szumów pojedynczych obserwacji. Na heatmapie z rysunku 4.5 konfiguracje $max_depth=8$ i $max_depth=10$ dają praktycznie identyczne AUC (0,779); wybór


głębszej wartości uzasadniony jest stabilnością rankingu cech przy tej samej wielkości lasu.

Pomocniczo ustawiono również parametr *min_samples_leaf=5*, który wymusza, by w każdym liściu drzewa znajdowało się co najmniej pięć obserwacji. Jest to dodatkowa bariera przeciwko nadmiernemu dopasowaniu, zapobiega tworzeniu liści reprezentujących pojedyncze rekordy, a zatem wzmacnia stabilność predykcji. Parametr *class_weight="balanced"* odpowiada za opisaną w sekcji 4.1.2 kompensację niebalansowania, a *random_state=42* zapewnia pełną powtarzalność wyników.

4.3.2. Ważność cech

Istotną zaletą Random Forest jest łatwość oszacowania wpływu poszczególnych cech na predykcję. Atrybut *feature_importances_* modelu zwraca znormalizowane wartości oparte na średnim zmniejszeniu nieczystości Gini w węzłach podziału, agregowane po wszystkich drzewach zespołu. Choć miara ta jest krytykowana za zawyżanie istotności cech numerycznych o wysokiej kardynalności, w zestawieniu z dobrze dobranymi cechami sekwencyjnymi i inżynierskimi daje obraz spójny z oczekiwaniami analityków kredytowych.

Na rysunku 4.6 przedstawiono dwadzieścia najistotniejszych cech, posortowanych malejąco. Na szczycie listy znalazły się zmienne związane z najnowszym i najbardziej dotkliwym zachowaniem płatniczym: *PAY_max*, *late_count* oraz *recent_pay_status*. Pierwsza, *PAY_max*, reprezentuje najgorszy status płatności w sześciomiesięcznym oknie. Wychwytuje zatem pojedyncze, skrajne epizody opóźnień, które nie byłyby widoczne w uśrednionych miarach. Druga, *late_count*, zlicza, w ilu z sześciu miesięcy klient był w jakimkolwiek opóźnieniu. Trzecia, *recent_pay_status*, odzwierciedla status płatności w ostatnim dostępnym miesiącu; w implementacji stanowi ona kopię *PAY_0* i plasuje się na liście istotności nieco niżej niż sam *PAY_0*, co jest naturalnym efektem konstrukcji Random Forest – losowy wybór podzbioru cech w węzłach powoduje „rozmywanie” istotności między cechami silnie skorelowanymi, a nie świadczy o niedopatrzeniu implementacyjnym. Dominacja tych trzech zmiennych potwierdza wnioski znane z literatury credit scoring: najlepszym predyktorem przyszłego niewywiązywania się ze zobowiązań jest świeża historia takich zdarzeń. Dla praktyki bankowej ma to wymierne znaczenie – sugeruje, że systemy wczesnego ostrzegania powinny w pierwszej kolejności reagować na zmianę statusu płatności w bieżącym cyklu rozliczeniowym.



Rysunek 4.6. Top 20 cech wg istotności w modelu Random Forest. Źródło: opracowanie własne.

W dalszej części rankingu pojawiają się cechy inżynierskie utworzone w rozdziale 3: *utilization_rate* (stosunek średniego salda do limitu), *BILL_trend* (zmiana salda między kwietniem a wrześniem), *severe_late* (flaga poważnego opóźnienia) oraz *payment_ratio* (relacja wpłat do rachunków). Fakt, że cechy te plasują się wyżej niż niektóre zmienne surowe z pliku źródłowego, stanowi liczbowy dowód wartości feature engineeringu – nie jest to jedynie deklaracja, lecz efekt widoczny w istotności atrybutów wyuczonego modelu.

W dolnej części rankingu znajdują się zmienne demograficzne: *AGE*, *EDUCATION*, *MARRIAGE* oraz *SEX*. Ich niska istotność jest obserwacją o dwóch konsekwencjach. Po pierwsze, metodologicznej: w tym zbiorze zachowanie płatnicze jest zdecydowanie silniejszym predyktorem niż profil demograficzny. Po drugie, etycznej i regulacyjnej: ograniczona waga zmiennych chronionych, takich jak płeć, zmniejsza ryzyko dyskryminacji pośredniej w modelu, co jest ważnym argumentem przed oceną zgodności z regulacjami (przede wszystkim z unijnym AI Act i dotychczasowym RODO).

4.4. Implementacja modelu XGBoost


XGBoost (eXtreme Gradient Boosting) buduje zespół drzew sekwencyjnie – każde kolejne drzewo koryguje błędy poprzedników – w odróżnieniu od niezależnego trenowania z agregacją głosowaniem stosowanego w Random Forest (szczegóły teoretyczne w sekcji 2.3.3). Efektem takiego podejścia jest zazwyczaj wyższa skuteczność predykcyjna, lecz także większa wrażliwość na hiperparametry oraz wyższe ryzyko *overfittingu*, wymagające staranniejszej regularyzacji. W pracy XGBoost pełni rolę modelu referencyjnego dla statycznego ujęcia problemu, to na nim najczęściej porównuje się nowe metody w benchmarkach credit scoring.

4.4.1. Strojenie hiperparametrów – Grid Search i Cross-Validation

Konfiguracja XGBoost w finalnej implementacji wygląda następująco:

```
xgb = XGBClassifier(
    n_estimators=800,
    learning_rate=0.02,
    max_depth=4,
    subsample=0.7,
    colsample_bytree=0.7,
    reg_alpha=0.1,
    reg_lambda=1.0,
    scale_pos_weight=(len(y) - sum(y)) / sum(y),
    random_state=42,
    eval_metric='auc'
)
```

Dobór kluczowej pary parametrów, *learning_rate* oraz *max_depth*, przeprowadzono w oparciu o siatkę wartości (grid search). Wyniki zaprezentowano na rysunku 4.7, również w postaci heatmapy AUC testowego. Zielone obramowanie wskazuje konfigurację optymalną, która okazała się spójna z zaleceniami twórców XGBoost: niski współczynnik uczenia (0,01–0,02) w połączeniu z niewielką głębokością drzew (3–4). W algorytmie boostingu każde drzewo wnosi niewielką korektę, a duża liczba iteracji pozwala ją stopniowo akumulować. Wysokie *learning_rate* przy dużej głębokości prowadzi do szybkiego przeuczenia, co w heatmapie widać jako ciemne pola w prawym dolnym narożniku.



Rysunek 4.7. XGBoost — grid search learning_rate i max_depth. Źródło: opracowanie własne.

Niskie *learning_rate*=0.02 wymaga rekompensaty w postaci dużej liczby iteracji. Wybrana wartość 800 okazała się wystarczająca, kolejne eksperymenty z *n_estimators*=1200 dawały już tylko znikomą poprawę AUC kosztem około dwukrotnie dłuższego trenowania. Dodatkowo zastosowano dwie techniki regularyzacji: stochastyczne próbkowanie zarówno obserwacji (*subsample*=0.7), jak i cech (*colsample_bytree*=0.7), oraz regularyzację L1 i L2 (*reg_alpha*=0.1, *reg_lambda*=1.0). Takie połączenie redukuje wariancję modelu przy zachowaniu wysokiej skuteczności predykcyjnej.

Walidacja krzyżowa (ang. cross-validation) zaprezentowana na rysunku 4.9 stanowi technikę oceny stabilności modelu, w każdej z pięciu iteracji inny fold pełni rolę zbioru walidacyjnego, a reszta służy do trenowania. Takie rozwiązanie pozwala oszacować wariancję metryki pomiędzy próbami, dając pojęcie o wrażliwości modelu na konkretny podział danych. W niniejszej pracy walidację krzyżową 5-fold zaprezentowano schematycznie, natomiast do właściwej oceny modeli przyjęto pojedynczy, stratyfikowany podział treningowo-testowy 70/30 opisany w sekcji 4.1.1. Powodem tej decyzji był koszt obliczeniowy: pełna walidacja krzyżowa wymagałaby pięciokrotnego trenowania modeli z


500 drzewami (Random Forest) i 800 iteracjami boostingu (XGBoost), co w połączeniu z eksperymentami dla kilkunastu kombinacji hiperparametrów, znacznie wydłużałoby czas pojedynczego cyklu badawczego. Stratyfikowany podział 70/30 z *random_state=42* daje stabilną, powtarzalną ocenę modelu, a wyniki na niezależnym zbiorze testowym nie wykazują oznak niestabilności, które uzasadniałyby koszty pełnego CV.

4.4.2. Analiza wkładu cech (SHAP values)

Jednym z głównych zarzutów stawianych modelom opartym na drzewach boostingu jest ich zredukowana interpretowalność w porównaniu z prostymi metodami scoringowymi. O ile w pojedynczym drzewie decyzyjnym da się odtworzyć logikę decyzji, o tyle w zespole ośmiuset drzew taka inspekcja byłaby bezużyteczna. Odpowiedzią na ten problem jest metoda SHAP (Shapley Additive exPlanations), której podstawą teoretyczną jest klasyczna teoria gier kooperacyjnych Shapleya. Każda cecha modelu traktowana jest jako „gracz”, a jej wkład do predykcji, jako odpowiednik wartości Shapleya w grze, tj. średniego wkładu tego gracza do wyniku końcowego, wyznaczonego po wszystkich możliwych koalicjach. Jest to jedyne sformułowanie spełniające jednocześnie trzy aksjomaty zaproponowane przez Lundberga i Lee (2017): lokalną dokładność (local accuracy), własność braku (missingness) oraz konsekwencję (consistency).

Rysunek 4.8 przedstawia dwie komplementarne wizualizacje wartości SHAP. Lewa część zawiera tak zwany beeswarm plot. Każda kropka odpowiada pojedynczej obserwacji zbioru testowego, a jej pozioma pozycja, wartości SHAP dla danej cechy przy tej obserwacji. Kolor kropki koduje wartość cechy: ciemnoczerwony – wartości wysokie, niebieski – niskie. Dzięki temu jeden wykres daje wgląd w cztery aspekty jednocześnie: kierunek wpływu cechy, jego rozpiętość, zależność od wartości cechy oraz rozkład populacji klientów.

Wyjaśnialność modelu XGBoost — wartości SHAP (n=1000)



Rysunek 4.8. Wyjaśnialność modelu XGBoost — wartości SHAP. Źródło: opracowanie własne.

Prawa część rysunku zawiera bar plot, zestawienie średniej wartości bezwzględnej SHAP dla każdej cechy. Jest to uśredniona, globalna istotność cech, analogiczna do ważności cech z sekcji 4.3.2, lecz oparta na innym fundamencie teoretycznym. Porównując obie wizualizacje z listą istotności Random Forest, można zauważyć wysoką zgodność uporządkowania: status płatności z ostatniego miesiąca, zbiorcza miara opóźnień oraz wskaźnik wykorzystania limitu konsekwentnie zajmują czołowe pozycje, niezależnie od algorytmu. Zgodność rankingów wzmacnia wiarygodność wniosków. Ranking cech nie jest efektem wybranej rodziny algorytmicznej, lecz odzwierciedla strukturę zależności w danych.

Dla praktyki bankowej istotne są szczególnie wyjaśnienia lokalne. SHAP pozwala wyjaśnić każdą pojedynczą predykcję modelu w postaci addytywnej: predykcja = wartość bazowa + suma wkładów cech. Dla analityka kredytowego oznacza to możliwość udzielenia klientowi precyzyjnej odpowiedzi, dlaczego jego wniosek został sklasyfikowany jako ryzykowny, z wymienieniem konkretnych cech, które przeważyły decyzję. W kontekście wymagań unijnego AI Act oraz postanowień RODO dotyczących zautomatyzowanego podejmowania decyzji (art. 22), zdolność do generowania wyjaśnień lokalnych na poziomie pojedynczej predykcji stanowi znaczącą przewagę XGBoost jako kandydata na model produkcyjny.

4.5. Walidacja i testowanie modeli w środowisku eksperymentalnym

Po zakończeniu trenowania każdy z trzech modeli jest ewaluowany na zamrożonym zbiorze testowym, tym samym dla Random Forest i XGBoost, a dla LSTM na jego odpowiedniku z tablicy trójwymiarowej `X_test_seq`. Główną metryką raportowaną w pętli trenującej jest ROC-AUC, obliczana funkcją `roc_auc_score` z pakietu `scikit-learn`:

```
y_pred_rf = rf.predict_proba(X_test)[: , 1]
y_pred_xgb = xgb.predict_proba(X_test)[: , 1]
y_pred_lstm = model.predict(X_test_seq).ravel()
```

Wybór ROC-AUC jako metryki wiodącej nie jest przypadkowy. Przy niezbalansowanym rozkładzie klas (78/22) accuracy bywa myląca, nawet klasyfikator zwracający zawsze klasę większościową osiąga 78% dokładności, choć z perspektywy biznesowej jest całkowicie bezużyteczny. ROC-AUC jest natomiast niezależna od wyboru progu klasyfikacyjnego oraz od proporcji klas, co czyni ją standardem w credit scoring. W kolejnym rozdziale zostanie ona uzupełniona o metryki progowe: precision, recall, F1, których omówienie pozwoli głębiej zinterpretować różnice między modelami z perspektywy kosztów błędnych decyzji kredytowych.

Zastosowano pojedynczy, stratyfikowany podział 70/30 opisany w sekcji 4.1.1; uzasadnienie rezygnacji z pełnej walidacji krzyżowej zostało omówione w sekcji 4.4.1. Rysunek 4.9 prezentuje schematycznie technikę 5-fold CV jako punkt odniesienia: w każdej iteracji inny fold pełni rolę walidacji, a pozostałe cztery służą trenowaniu. Wariant stratyfikowany zachowuje w każdym foldzie proporcję klas 78/22, co przy niezbalansowanych danych jest wymogiem koniecznym. Stabilność wyników potwierdza dodatkowo raportowana w rozdziale 5 wariancja AUC, obliczona na podstawie 40 bootstrapowanych powtórzeń zbioru testowego. Jeśli model jest stabilny w pojedynczym podziale, przejście do pełnego CV zmienia jedynie przedział ufności, a nie ranking metod.

Walidacja krzyżowa 5-fold (stratified) — rotacja zbioru walidacyjnego

	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Iteracja 1	walidacja	trenowanie	trenowanie	trenowanie	trenowanie
Iteracja 2	trenowanie	walidacja	trenowanie	trenowanie	trenowanie
Iteracja 3	trenowanie	trenowanie	walidacja	trenowanie	trenowanie
Iteracja 4	trenowanie	trenowanie	trenowanie	walidacja	trenowanie
Iteracja 5	trenowanie	trenowanie	trenowanie	trenowanie	walidacja

Zbiór treningowy
 Zbiór walidacyjny

Rysunek 4.9. Walidacja krzyżowa 5-fold (schemat). Źródło: opracowanie własne.

Każdy z wytrenowanych modeli jest na końcu serializowany do pliku: Random Forest i XGBoost za pomocą *joblib.dump* (jako pliki *.pkl*), LSTM metodą *model.save* biblioteki Keras do formatu *.keras*. Obiekty skalujące (*scaler.pkl* dla modeli statycznych oraz *lstm_scalers.pkl* dla modelu sekwencyjnego) zapisywane są razem z modelami, ponieważ bez nich serwis predykcyjny nie byłby w stanie odtworzyć przestrzeni cech, w której modele zostały wytrenowane. Spójność między etapem trenowania a wnioskowaniem jest warunkiem koniecznym stabilnych predykcji – nawet drobna zmiana w rozkładach cech (różne parametry *mean* i *std* w skalowaniu) prowadziłaby do nieprzewidywalnego zachowania modeli w środowisku produkcyjnym.

Podsumowując etap implementacyjno-treningowy: trzy modele – każdy reprezentujący inną rodzinę algorytmiczną i wykorzystujący dane w odmienny sposób (Random Forest i XGBoost jako klasyfikatory statyczne operujące na zagregowanym wektorze cech oraz LSTM jako klasyfikator sekwencyjny uczący się progresji zachowań w czasie) – zostały wytrenowane, zwalidowane i zapisane w postaci artefaktów gotowych do eksploatacji. Ich porównanie ilościowe, ocena z perspektywy metryk biznesowych oraz interpretacja różnic pomiędzy ujęciem statycznym a dynamicznym są przedmiotem rozdziału 5.

Rozdział 5. Analiza wyników i ocena modeli

5.1. Metryki oceny jakości modeli klasyfikacyjnych

5.1.1. Dokładność, precyzja, czułość, F1-Score

5.1.2. Krzywa ROC i pole pod krzywą (AUC-ROC)

5.1.3. Macierz pomyłek i analiza błędów klasyfikacji

5.2. Wyniki modeli – zestawienie porównawcze

5.2.1. Wyniki modelu LSTM

5.2.2. Wyniki modelu Random Forest

5.2.3. Wyniki modelu XGBoost

5.3. Wzajemne porównanie modeli LSTM, Random Forest i XGBoost

5.4. Porównanie z klasycznymi metodami scoringowymi i istniejącymi rozwiązaniami

5.5. Interpretowalność modeli i ich przydatność decyzyjna

5.6. Dyskusja wyników i weryfikacja hipotez badawczych

Zakończenie

Bibliografia

[1] Ustawa z dnia 29 sierpnia 1997 r. Prawo bankowe (tekst jednolity Dz.U. 2024 poz. 1646 z późn. zm.).

[2] Thomas L. C., Edelman D. B., Crook J. N., *Credit scoring and its applications*. Philadelphia: Society for Industrial and Applied Mathematics, 2002.

[3] Anderson R., *The credit scoring toolkit: Theory and practice for retail credit risk management and decision automation*. Oxford: Oxford University Press, 2007.

- [4] Siddiqi N., *Credit risk scorecards: Developing and implementing intelligent credit scoring*. Hoboken: John Wiley & Sons, 2005.
- [5] Hand D. J., Henley W. E., „Statistical classification methods in consumer credit scoring: A review” w *Journal of the Royal Statistical Society: Series A*, t. 160, nr 3, 1997, s. 523-541.
- [6] Thomas L. C., „A survey of credit and behavioural scoring: Forecasting financial risk of lending to consumers” w *International Journal of Forecasting*, t. 16, nr 2, 2000, s. 149-172.
- [7] Komisja Nadzoru Finansowego, *Rekomendacja T dotycząca dobrych praktyk w zakresie zarządzania ryzykiem detalicznych ekspozycji kredytowych*. Warszawa: KNF, 2013.
- [8] Komisja Nadzoru Finansowego, *Rekomendacja S dotycząca dobrych praktyk w zakresie zarządzania ekspozycjami kredytowymi zabezpieczonymi hipotecznie*. Warszawa: KNF, 2019.
- [9] Europejski Urząd Nadzoru Bankowego, *Wytyczne w sprawie udzielania i monitorowania kredytów (EBA/GL/2020/06)*. 2020.
- [10] Lessmann S., Baesens B., Seow H.-V., Thomas L. C., „Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research” w *European Journal of Operational Research*, t. 247, nr 1, 2015, s. 124-136.
- [11] Baesens B. i in., „Benchmarking state-of-the-art classification algorithms for credit scoring” w *Journal of the Operational Research Society*, t. 54, nr 6, 2003, s. 627-635.
- [12] Bellotti T., Crook J., „Forecasting and stress testing credit card default using dynamic models” w *International Journal of Forecasting*, t. 29, nr 4, 2013, s. 563-574.
- [13] Yeh I.-C., Lien C.-H., „The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients” w *Expert Systems with Applications*, t. 36, nr 2, 2009, s. 2473-2480.
- [14] Hastie T., Tibshirani R., Friedman J., *The elements of statistical learning: Data mining, inference, and prediction*, wyd. 2. New York: Springer, 2009.
- [15] Goodfellow I., Bengio Y., Courville A., *Deep learning*. Cambridge: MIT Press, 2016.
- [16] Hochreiter S., Schmidhuber J., „Long short-term memory” w *Neural Computation*, t. 9, nr 8, 1997, s. 1735-1780.
- [17] Breiman L., „Random forests” w *Machine Learning*, t. 45, nr 1, 2001, s. 5-32.

- [18] Chen T., Guestrin C., „XGBoost: A scalable tree boosting system” w *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, San Francisco, 2016, s. 785-794.
- [19] Wang C. i in., „A deep learning approach for credit scoring of peer-to-peer lending using attention mechanism LSTM” w *IEEE Access*, t. 7, 2019, s. 2161-2168.
- [20] Babaev D. i in., „E.T.-RNN: Applying deep learning to credit loan applications” w *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, Anchorage, 2019, s. 2183-2190.
- [21] Clements J. M. i in., „Sequential deep learning for credit risk monitoring with tabular financial data”, arXiv:2012.15330, 2020 [dostęp: 30.05.2026]. Dostępne w: <https://arxiv.org/abs/2012.15330>.
- [22] Baesens B., Roesch D., Scheule H., *Credit risk analytics: Measurement techniques, applications and examples in SAS*. Hoboken: John Wiley & Sons, 2016.
- [23] Lundberg S. M., Lee S.-I., „A unified approach to interpreting model predictions” w *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, 2017, s. 4765-4774.
- [24] Molnar C., *Interpretable machine learning: A guide for making black box models explainable*, wyd. 2, 2022 [dostęp: 30.05.2026]. Dostępne w: <https://christophm.github.io/interpretable-ml-book/>.
- [25] Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2024/1689 z dnia 13 czerwca 2024 r. ustanawiające zharmonizowane przepisy dotyczące sztucznej inteligencji (akt w sprawie sztucznej inteligencji). Dz.U. UE L, 2024/1689.
- [26] Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2016/679 z dnia 27 kwietnia 2016 r. w sprawie ochrony osób fizycznych w związku z przetwarzaniem danych osobowych (RODO). Dz.U. UE L 119, 2016.
- [27] Chevalier G., The LSTM Cell [grafika], licencja CC BY-SA 4.0, 2018 [dostęp: 31.05.2026]. Dostępne w Wikimedia Commons: https://commons.wikimedia.org/wiki/File:The_LSTM_Cell.svg.
- [28] Sirakorn, Ensemble Bagging [grafika], licencja CC BY-SA 4.0, 2020 [dostęp: 31.05.2026]. Dostępne w Wikimedia Commons: https://commons.wikimedia.org/wiki/File:Ensemble_Bagging.svg.

[29] Sirakorn, Ensemble Boosting [grafika], licencja CC BY-SA 4.0, 2020 [dostęp: 31.05.2026]. Dostępne w Wikimedia Commons:
https://commons.wikimedia.org/wiki/File:Ensemble_Boosting.svg.

Spis tabel

Spis rysunków i wykresów

Rysunek 1.1. Ewolucja metod oceny zdolności kredytowej

Rysunek 1.2. Cykl życia ekspozycji kredytowej i miejsce oceny

Rysunek 2.1. Taksonomia metod uczenia maszynowego

Rysunek 2.2. Schemat komórki LSTM

Rysunek 2.3. Porównanie konstrukcji zespołu: bagging i boosting

Rysunek 4.1. Podział danych: train / walidacja / test

Rysunek 4.2. Wpływ techniki SMOTE na balans klas

Rysunek 4.3. Krzywe uczenia modelu LSTM

Rysunek 4.4. Wpływ hiperparametrów LSTM na AUC walidacji

Rysunek 4.5. Random Forest — wpływ `n_estimators` i `max_depth` na AUC

Rysunek 4.6. Top 20 cech wg istotności w modelu Random Forest

Rysunek 4.7. XGBoost — grid search `learning_rate` i `max_depth`

Rysunek 4.8. Wyjaśnialność modelu XGBoost — wartości SHAP

Rysunek 4.9. Walidacja krzyżowa 5-fold (schemat)